Statistik

Siegfried Hörmann

TU Graz

Inhalt

1. Einleitung.
2. Grundbegriffe der EDA.
3. Datenbeispiel in R.
4. Statistiken von Zufallsstichproben.
5. Punktschätzer.
6. Konfidenzintervalle.
7. Hypothesentests.
8. Zweistichprobenproblem.
9. Asymptotische Analyse.
10. Lineare Modelle.

Kapitel 1

Kapitel 1

1. Einleitung.

1.1. Aufgabe der Statistik.

1.2. Stichproben.

1.3. Datentypen.

1.4. Deskriptive Statistik.

1.5. Inferenzstatistik.

1.6. Schätzen und Testen.

1.7. Daten erheben.

1.8. Mathematischer Rahmen.

Aufgabe der Statistik

In fast allen Bereichen unseres Lebens werde Daten gesammelt:

- Forschung (Gensequenzen, Populationszahlen, etc.)
- Klima (Temperaturverläufe, Niederschlagsmengen, etc.)
- Wirtschaft (Verlauf von Aktienkursen, Verkaufszahlen, BIP, etc.)
- Internet (Suchverhalten, Likes, etc.)
- ...

Aufgabe der Statistik ist es Daten aufzubereiten (evtl. auch zu erheben), zusammenzufassen und Schlüsse zu ziehen.

Stichproben

Grundlage der statistischen Untersuchung ist eine Population, also die Gesamtheit der Objekte (z.B. alle Medikamente einer bestimmten Charge, alle Österreicher, etc.) die analysiert werden sollen.

Falls die gewünschte Information von allen Objekten der Population vorhanden ist, spricht man von einem Zensus.

In der Praxis ist ein Zensus meist zu teuer und zu aufwendig. Anstelle dessen wird eine Teilpopulation—eine Stichprobe (engl. sample)—erhoben. Ein einzelnes Element dieser Stichprobe nennen wir Beobachtung.

Datentypen

Üblicherweise sind wir an bestimmten Merkmalen der Population interessiert (z.B. Gehalt eines Wirkstoffs in einem Medikament, Beruf oder Alter der Österreicher, etc.). Die erhobenen Daten können dabei verschiedene Formen annehmen:

- numerische Daten (Gewicht, Alter, Größe, etc.)
- kategorische Daten (Beruf, Geschlecht, etc.)
- ordinale Daten (Noten, Gefahrenstufen, Offiziersrang, etc.)

Wenn wir von jedem Objekt nur eine Ausprägung erfassen, spricht man von univariaten Daten, im Gegensatz zu multivariaten Daten, bei denen mehrere Ausprägungen gleichzeitig erfasst werden. Z.B. (Alter, Gewicht, Körpergröße) oder (systolischer Blutdruck, diastolischer Blutdruck).

Beachte, dass multivariate Daten numerische und kategorische Komponenten enthalten können.

Datentypen

Dank verbesserter Speichermedien und Rechenleistung werden immer komplexere Datenstrukturen analysiert:

- funktionale Daten (Wachstumskurven, Hochfrequenzdaten, Grauwertbilder, etc.)
- objektorientierte Daten (z.B. fMRT, keine euklidische Geometrie)
- Netzwerkdaten

Hier nicht.

Deskriptive Statistik

Ausgangspunkt einer statistischen Untersuchung ist in vielen Fällen eine empirische Untersuchung der Daten. Es geht darum wesentliche Merkmale der Daten zu beschreiben und zusammenzufassen. Dabei verwendet man Methoden der deskriptiven Statistik (Kapitel 2 und 3).

Hier kommen häufig graphische Methoden zur Anwendung:

- Histogramme
- Liniendiagramme
- Tortendiagramme
- Fehlerbalken
- Boxplot
- Streudiagramme
- qq-plot
- etc.

Deskriptive Statistik

Außerdem werden wichtige Kennzahlen bestimmt:

- Mittelwert
- Median
- Quantile
- Korrelationskoeffizient
- Standardabweichung
- Schiefe (skewness)
- Exzess (kurtosis)
- etc.

All dies geschieht heute natürlich nicht händisch sondern wird mit Hilfe von statistischer Software (z.B. SPSS, SAS, Excel, R) erledigt. Wir lernen in diesem Kurs Grundzüge von R.

Beispiel: *Old faithful Geysir*

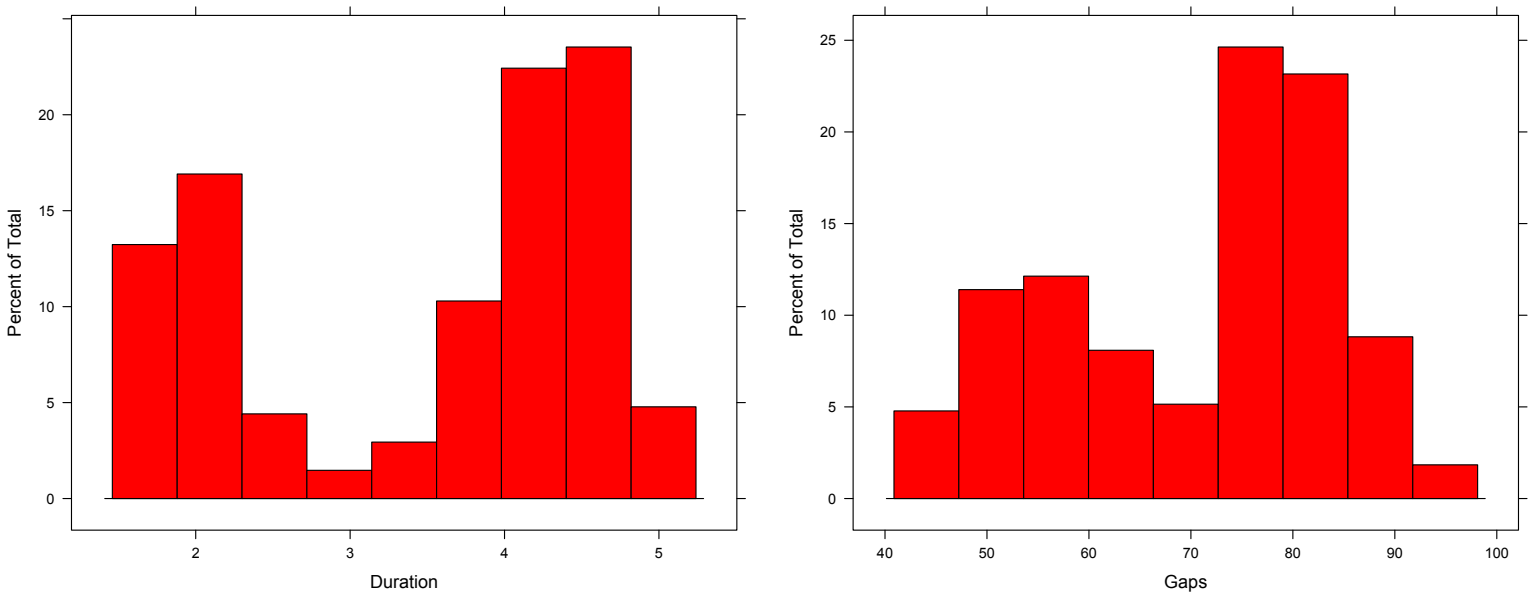
Die Softwarepaket `R` enthält eine Reihe von illustrativen Datensätzen. Wir wählen den data.frame "`faithful`" aus.

Old faithful heißt ein Geysir im Yellowstone Nationalpark der für seine regelmäßigen Eruptionen bekannt ist. Der Datensatz beinhaltet zwei Variablen: Länge des Ausbruchs (in Minuten), Dauer zum nächsten Ausbruch (in Minuten). Wir haben 272 Datenpunkte:

	eruptions	waiting
1	3.600	79
2	1.800	54
3	3.333	74
4	2.283	62
5	4.533	85
...	...	...
272	4.467	74

Beispiel: *Old faithful Geysir*

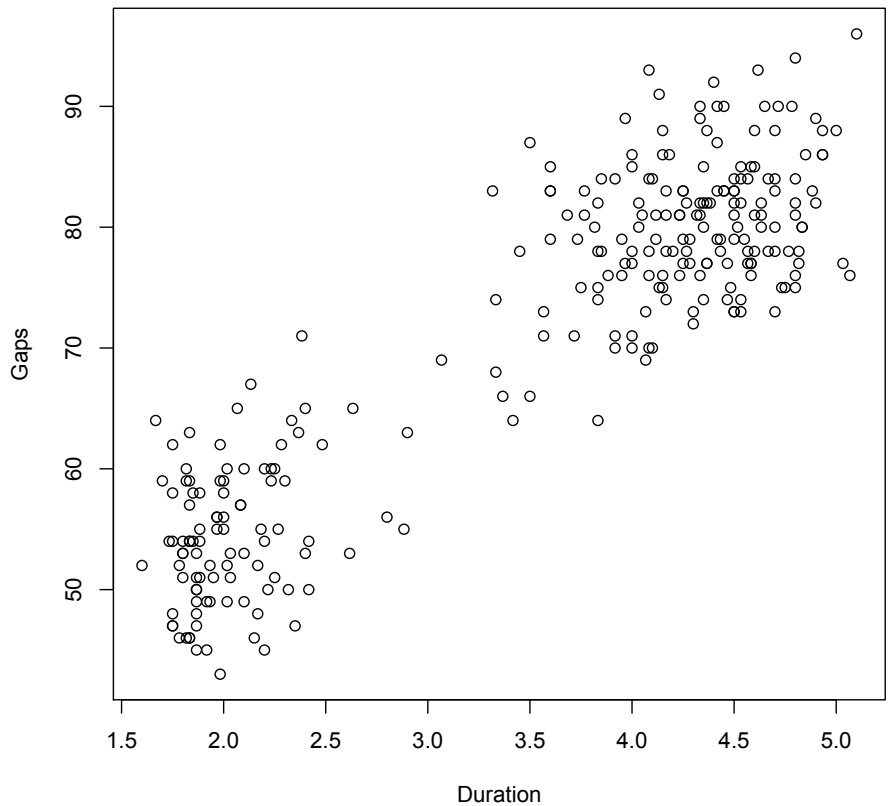
Mithilfe eines Histogramms sehen wir uns an wie die Ausbruchslängen und die Zeiten zwischen den Eruptionen verteilt sind.



Auffällig ist eine bimodale Verteilung in beiden Fällen. Eine naheliegende Frage ist, ob die Ausbruchslänge mit der Wartezeit zur nächsten Eruption korreliert ist.

Beispiel: *Old faithful Geysir*

Das Streudiagramm legt nahe, dass längere Eruptionszeiten eine längere Wartezeit zur nächsten Eruption implizieren:



Statistische Inferenz

Nachdem wir uns mit deskriptiven Methoden einen Überblick von den Daten verschafft haben, möchten wir gerne von der Stichprobe ausgehend Rückschlüsse auf die gesamte Population machen. Diesen Bereich nennt man Inferenzstatistik (Kapitel 4–8).

Um die Idee hinter statistischer Inferenz zu verstehen, müssen wir vorwegschicken (Genaueres später), dass die mathematischen Begriffe und Formulierungen in der Statistik aus der Wahrscheinlichkeitstheorie stammen.

Beobachtungen werden mittels Zufallsvariablen modelliert und Aussagen über die Population sind Aussagen über die Verteilung der Zufallsvariablen (ZV).

Statistische Inferenz

Während in der W-theorie die Verteilung der ZVen als bekannt vorausgesetzt wird und anschließend die Wahrscheinlichkeit, dass die ZV eine bestimmte Ausprägung hat, berechnet wird, gehen wir in der Inferenzstatistik genau den umgekehrten Weg: wir nehmen eine Realisierung der ZVen als Grundlage und versuchen damit Rückschlüsse auf die unbekannte Verteilungsfunktion, also auf die Gesamtpopulation zu machen.

Beispiel

W-theoretische Fragestellung: Wir nehmen an, dass 90% aller Autofahrer in Österreich den Sicherheitsgurt verwenden. Frage: wie groß ist die Wahrscheinlichkeit, dass bei 100 Verhehrskontrollen alle Personen angeschnallt sind?

Statistische Fragestellung: Von allen Verkehrskontrollen in Österreich im Jahr 2017 wurden 100 zufällig ausgewählt und im Rahmen einer Verkehrssicherheitsstudie nachträglich ausgewertet. Von den 100 Personen waren 18 nicht angeschnallt. Ist die Annahme, dass mindestens 90% aller Autofahrer in Österreich einen Sicherheitsgurt verwenden aufgrund dieses Ergebnisses haltbar?

Schätzen und Testen

Die zwei wichtigsten Teilgebiete der Inferenzstatistik sind die Schätztheorie (Kapitel 4) und die Testtheorie (Kapitel 5).

Das oben genannte Beispiel gehört zum Bereich der Testtheorie: eine Hypothese bezüglich der gesamten Population (nämlich dass mindestens 90% der Autofahrer in Österreich einen Sicherheitsgurt verwenden) soll anhand einer Stichprobe angenommen oder verworfen werden.

Grob formuliert, gibt ein statistischer Test Auskunft darüber wie wahrscheinlich es ist, dass eine Stichprobe unter Annahme der Hypothese eine gewisse Ausprägung annimmt.

Liegt diese Wahrscheinichkeit unter einem vorgegebenen Signifikanzniveau dann wird die Hypothese verworfen.

Beispiel zum Schätzen

Frau Maier passiert jeden Tag am Weg zur Arbeit eine Ampel. Ist die Ampel rot, dann notiert Sie sich seit 10 Tagen die verbleibende Zeit (in Sekunden) bis die Ampel auf grün schaltet:

$$9.7,\ 28.9,\ 3.8,\ 7.6,\ 26.3,\ 27.3,\ 15.2,\ 6.3,\ 20.2,\ 14.4$$

Wir möchten anhand der Stichprobe, die Gesamtlänge der Rotphase schätzen.

Wie machen wir das? Siehe Kapitel 4.

Daten erheben

Neben der Aufbereitung und Analyse von Daten ist eine weitere Aufgabe der Statistik Methoden zum korrekten Erheben von Daten bereitzustellen und zu entwickeln. Viele Studien sind unzulänglich weil Daten nicht ordnungsgemäß erhoben wurden.

Ein wichtiges und häufig auftretendes Problem ist, dass die Zielpopulation nicht mit jener Population übereinstimmt in der wir die Stichprobe entnommen haben. In diesem Fall ist die Stichprobe nicht repräsentativ.

Beispiel 1: eine Umfrage im Forum der Kronenzeitung gibt lediglich Aufschluss über die Population der Kroneleser und nicht über die etwaige Zielpopulation (z.B. alle Österreicher).

Beispiel 2: Telefonumfragen über Festnetz sind heutzutage sehr zweifelhaft, weil jüngere Personen kaum noch Festnetzanschlüsse besitzen.

Daten erheben

Beispiel 3: An einer Umfrage die um 10h morgens stattfindet, werden viele berufstätige Menschen nicht teilnehmen können. Ergo könnte diese Gruppe in der Stichprobe unterrepräsentiert sein.

Beispiel 4: Beim oben erwähnten Gurtbeispiel sind nur Personen erfasst die bei einer Verkehrskontrolle angehalten wurden. Einige von Ihnen wurde vielleicht eben wegen der Tatsache nicht angeschnallt zu sein, angehalten.

Daten erheben

Theoretisch ließe sich das Problem einfach lösen: bei einer endlichen Population (Anzahl gleich N) können wir jedem Element in der Population eindeutig eine Zahl in $\{1, \ldots, N\}$ zuordnen die anschließend zufällig (z.B. mit einem Zufallszahlengenerator) gezogen werden. Wir erhalten eine sogenannte Zufallsstichprobe.

Praktisch ist dies oft nicht durchführbar und es obliegt dann der eigenen Einschätzung ob die Stichprobe repräsentativ ist oder nicht.

Wenn möglich, dann werden Stichproben mit Methoden der Versuchsplanung erhoben. Dabei soll die Stichprobe optimal für den jeweiligen Versuch ausgewählt werden.

Daten erheben

Beispiel: Regelmäßige Einnahme von Aspirin soll angeblich vorbeugend gegen Herzinfarkt wirken. Um dies nachzuweisen wurde eine großangelegte Studie durchgeführt. Das geplante Experiment (designed experiment) wurde wie folgt durchgeführt: die Menge der Testpersonen wurde in eine Kontrollgruppe (control group) und Experimentalgruppe (treatment group) unterteilt (zufällige Zuweisung). Die Kontrollgruppe (11.034 Probanden) wurde mit einem Placebo das genau aussah wie Aspirin versorgt, während die Experimentalgruppe (11.037 Probanden) echtes Aspirin erhielt.

Aus der Kontrollgruppe hatten 189 Probanden über die Dauer der Studie hinweg einen eine Herzinfarkt, in der Experimentalgruppe nur 104 Probanden. Die statistische Frage: ist der Unterschied signifikant oder liegt er im Bereich einer zufälligen Schwankung?

Obige Fragestellung ist ein sogenanntes Zweistichprobenproblem (Kapitel 8).

Daten erheben

In den vorangehenden Beispielen sind wir davon ausgegangen, dass wir am Experiment mitwirken und durch Wiederholen des Experiments unter gleichen Bedingungen eine Stichprobe generieren: Umfragen, Probanden, etc.

In manchen Bereichen können wir allerdings kein Experiment durchführen, sondern sind lediglich Beobachter. Ein klassisches Beispiel sind Zeitreihen. Die Beobachtungen stammen hier von einem laufenden Prozess und es besteht nicht die Möglichkeit der Replikation.

Beispiel: Wir wollen den Niederschlag in Graz analysieren. Wir messen über mehrere Jahre hinweg jeden Tag die Niederschlagsmenge.

- Wir können keine zusätzliche Daten generieren.
- Die Beobachtungen sind vermutlich abhängig.

Daten erheben

Versuchsplanung oder Zeitreihenanalyse sind eigene wissenschaftliche Disziplinen und überschreiten den Rahmen dieser Vorlesung.

Hier werden wir vorweg bestimmte Annahmen treffen, die uns eine geeignete Stichprobe garantieren.

Dazu und zur weiteren Theorie brauchen wir eine geeignete mathematische Sprache.

Mathematischer Rahmen

In der mathematischen Statistik verwenden wir die Sprache der Wahrscheinlichkeitstheorie um einzelne Beobachtungen oder Stichproben zu modellieren und zu beschreiben. Unter einer Stichprobe verstehen wir entweder eine Folge von Zufallsvariablen $X_1, X_2, \ldots, X_n$ (als mathematisches Modell) oder deren Realisierung $x_1, \ldots, x_n$ (als konkrete Beobachtung). Wir bezeichnen mit n den Stichprobenumfang (sample size).

In dieser Vorlesung beschränken wir uns großteils auf Zufallsstichproben (random sample).

Definition

Eine Zufallsstichprobe vom Umfang n aus der Population $F(x)$ ist eine Folge $X_1, X_2, \ldots, X_n$ von i.i.d. Zufallsvariablen mit Verteilungsfunktion $F(x)$.

Mathematischer Rahmen

Die Zufallsvariablen X_k sind auf einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{A}, P)$ definiert.

Beachte dass bei dieser Modellierung Ω üblicherweise nicht mit der Zielpopulation gleichzusetzten ist. Eine Stichprobe zu nehmen heißt nicht mehrere $\omega \in \Omega$ zu ziehen, sondern wir ziehen nur ein ω!

Beispiel: Wir nehmen das "Angurtebeispiel". Die Population ist in diesem Fall die Menge aller Österreicher (mit Führerschein). Sagen wir es gibt N derartige Personen. Wir nummerieren diese mit $1, \ldots, N$. Also ist die Population gleich $\{1, \ldots, N\}$. Wenn wir 100 Autofahrer testen, ziehen wir 100 mal mit Zurücklegen aus dieser Menge. Also ist Ω in diesem Fall gleich $\{1, \ldots, N\}^{100}$.

Nehmen wir an, dass die Autofahrer $1, \ldots, K$ jene mit Gurt sind. Dann ist $X_k(\omega) = I\{\omega_k \leq K\}$, mit $\omega = (\omega_1, \ldots, \omega_N)$.

Mathematischer Rahmen

Die ZVe X_k nimmt die Werte 0 und 1 Wahrscheinlichkeit $1-p$ und p an, wobei $p = K/N$. Die Verteilung von X_k ist also durch den (unbekannten) Parameter p festgelegt.

Aufgrund der angenommenen Unabhängigkeit kennen wir die Verteilung der gesamten Stichprobe.

Insbesondere gilt $S_{100} = X_1 + \cdots + X_{100}$, dass

$$P(S_{100} = k) = \binom{100}{k} p^k (1-p)^{100-k}.$$

Mathematischer Rahmen

Es sei abschließend folgender wichtiger Satz aus der Wahrscheinlichkeitstheorie erwähnt:

Satz (Fundamentalsatz der Statistik (Glivenko-Cantelli))

Sei (X_n) eine i.i.d. Folge mit Verteilung $F(x) = P(X_k \leq x)$. Sei

$$F_n(x) = \frac{1}{n} \sum_{k=1}^{n} I\{X_k \leq x\}$$

die empirische Verteilung der Stichprobe. Dann gilt:

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \to 0 \quad \textit{fast sicher}$$

Anders gesagt: ist die Stichprobe groß genug, dann können wir die unbekannte Verteilung beliebig gut approximieren. (Kapitel 9.)